Documento de Especificación de Requerimientos

Sistema Automatizado de Doblaje de Vídeo con Inteligencia Artificial
(Transcripción · Corrección · Traducción · Clonación de Voz · Sincronización Labial)

Versión 2.0 (extendida)
Julio de 2026
Clasificación: Uso interno / Proyecto personal

Control de versiones

Versión	Fecha	Descripción	Autor
1.0	Julio 2026	Versión inicial del documento de especificación.	Equipo del proyecto
2.0	Julio 2026	Versión ampliada: se incorporan glosario, arquitectura de despliegue, matriz de riesgos, plan por fases y anexos técnicos.	Equipo del proyecto

Índice

1. Introducción

- 1.1 Propósito del documento
- 1.2 Objetivo general
- 1.3 Objetivos específicos
- 1.4 Alcance del sistema
- 1.5 Definiciones, acrónimos y abreviaturas
- 1.6 Enfoque tecnológico recomendado

2. Descripción general del sistema

- 2.1 Perspectiva del producto
- 2.2 Funciones principales
- 2.3 Características de los usuarios
- 2.4 Restricciones generales
- 2.5 Supuestos y dependencias

3. Requisitos funcionales (RF-01 a RF-13)

4. Requisitos no funcionales

5. Arquitectura del sistema

- 5.1 Arquitectura del pipeline
- 5.2 Arquitectura de despliegue
- 5.3 Flujo de datos y formatos intermedios
- 5.4 Gestión de errores y reintentos

6. Fase previa de investigación tecnológica

7. Gestión de riesgos

8. Plan de implementación por fases

9. Criterios de aceptación y estrategia de pruebas

- 10. Anexos

Anexo A — Estructura de carpetas propuesta

Anexo B — Ejemplo de configuración del pipeline

Anexo C — Glosario extendido

1. Introducción

1.1 Propósito del documento

El propósito de este documento es especificar de forma clara, completa y verificable los requisitos funcionales y no funcionales del sistema automatizado de doblaje de vídeo basado en inteligencia artificial. Este documento sirve como base de referencia para el diseño, la implementación, las pruebas y la validación del sistema, y está dirigido tanto a quien lo desarrolle (equipo técnico o agente de IA encargado de la implementación) como a quien deba validar que el resultado final cumple con lo solicitado.

1.2 Objetivo general

Diseñar e implementar un pipeline end-to-end, modular y desacoplado, capaz de recibir uno o varios vídeos como entrada y producir automáticamente una versión doblada al español, sincronizada y con subtítulos, minimizando la intervención manual y el coste operativo, priorizando en todo momento el uso de tecnologías de código abierto ejecutadas de forma local.

1.3 Objetivos específicos

- Automatizar de extremo a extremo el proceso de doblaje, desde la ingesta del vídeo original hasta la entrega del vídeo final doblado y subtitulado.
- Garantizar que la voz doblada conserve el timbre, la emoción, la velocidad y el tono de la voz original mediante técnicas de clonación de voz.
- Adaptar el texto traducido para que la duración locutada sea compatible con el vídeo original, respetando pausas y respiraciones.
- Permitir la ejecución tanto en hardware local como en proveedores de GPU alquilada, sin modificar el código.
- Minimizar los costes operativos, evitando APIs de pago y suscripciones recurrentes.
- Permitir el procesamiento por lotes de grandes volúmenes de vídeos sin intervención manual.
- Mantener una arquitectura modular que permita sustituir cualquier tecnología del pipeline sin rediseñar el sistema completo.

1.4 Alcance del sistema

Dentro del alcance:

- Ingesta, extracción y análisis de vídeos en formatos MP4, MKV, MOV y AVI.
- Separación de voz, música y efectos.
- Transcripción automática con marcas de tiempo, puntuación y detección de idioma.
- Corrección automática del texto transcrito mediante un modelo de lenguaje.
- Traducción contextual del texto al español.
- Adaptación del texto traducido para ajustarse a la duración del audio original.
- Clonación de voz y síntesis de audio en español.
- Sincronización temporal del audio generado con el vídeo original.
- Sincronización labial opcional.
- Mezcla final del vídeo, audio y subtítulos.
- Generación de subtítulos en español, inglés y bilingües en formatos SRT, VTT y ASS.
- Procesamiento masivo por lotes sobre carpetas completas de vídeos.
- Despliegue en local y en proveedores de GPU alquilada mediante contenedores Docker.

Fuera del alcance:

- Desarrollo de una interfaz gráfica de usuario avanzada; se requiere únicamente un mecanismo de ejecución mediante un único punto de disparo.
- Doblaje a idiomas distintos del español en esta primera versión (aunque la arquitectura debe permitir añadir nuevos idiomas de destino en el futuro).

- Edición manual de vídeo o efectos visuales ajenos al doblaje y la sincronización labial.
- Distribución o publicación de los vídeos resultantes en plataformas de terceros.

1.5 Definiciones, acrónimos y abreviaturas

Término	Definición
Pipeline	Secuencia de módulos de procesamiento encadenados, donde la salida de un módulo es la entrada del siguiente.
TTS	Text-to-Speech: síntesis de voz a partir de texto.
Voice Cloning	Técnica que permite generar voz sintética que imita el timbre y las características de una voz real.
Lip Sync	Sincronización labial: ajuste del movimiento de los labios en el vídeo para que coincida con el nuevo audio.
VRAM	Memoria de vídeo disponible en la GPU, relevante para determinar qué modelos de IA pueden ejecutarse.
CUDA / ROCm	Plataformas de cómputo en GPU de NVIDIA (CUDA) y AMD (ROCm) utilizadas para acelerar los modelos de IA.
Forced Alignment	Técnica que alinea texto y audio a nivel de palabra o fonema para obtener marcas de tiempo precisas.
Mux / Mezcla	Proceso de combinar en un único archivo las pistas de vídeo, audio y subtítulos.
SRT / VTT / ASS	Formatos de archivo de subtítulos ampliamente soportados por reproductores de vídeo.
RF / RNF	Abreviaturas utilizadas en este documento para referirse a Requisito Funcional y Requisito No Funcional, respectivamente.

1.6 Enfoque tecnológico recomendado

Este documento evita fijar herramientas concretas como requisito cerrado (por ejemplo, "usar Whisper y XTTS"), ya que dicha rigidez podría dejar obsoleto el sistema rápidamente ante la velocidad de evolución del ecosistema de IA generativa. En su lugar, se exige una fase inicial de investigación tecnológica comparativa antes de cada etapa de implementación (ver Sección 6), evaluando calidad, rendimiento, requisitos de GPU, tipo de licencia, actividad de mantenimiento de la comunidad y facilidad de integración, justificando técnicamente la elección final de cada componente del pipeline.

2. Descripción General del Sistema

2.1 Perspectiva del producto

El sistema se concibe como una herramienta autónoma de procesamiento por lotes, ejecutada localmente o sobre infraestructura de GPU alquilada, que no depende de servicios de pago de terceros para su funcionamiento. No sustituye a un estudio de doblaje profesional en todos los casos de uso, pero busca acercarse a su calidad mediante técnicas de clonación de voz y adaptación de texto, reduciendo drásticamente el coste y el tiempo de producción.

2.2 Funciones principales

- Ingesta y análisis de vídeo (extracción de audio, vídeo, subtítulos y metadatos).
- Separación de fuentes de audio (voz / música / efectos).
- Transcripción automática multilingüe.
- Corrección lingüística automática del texto transcrito.
- Traducción contextual al español.
- Adaptación del texto para ajuste temporal del doblaje.
- Clonación de voz y síntesis de audio.
- Sincronización temporal y, opcionalmente, labial.
- Mezcla final y generación de subtítulos multilenguaje.
- Procesamiento por lotes con cola automática.
- Gestión automática y eficiente de recursos de GPU.

2.3 Características de los usuarios

El sistema está pensado para un usuario único o un equipo reducido, con conocimientos técnicos suficientes para desplegar el sistema mediante Docker, pero que no desea operar el pipeline mediante comandos manuales durante el uso habitual. El usuario final espera un flujo de trabajo iniciado con una única acción ("un solo botón"), sin necesidad de conocimientos de los modelos de IA subyacentes.

2.4 Restricciones generales

- El sistema debe basarse, en la medida de lo posible, en software de código abierto.
- No se debe depender de APIs de pago por uso para el funcionamiento estándar del sistema.
- El único coste variable admitido es el alquiler temporal de GPU en la nube.
- El sistema debe poder ejecutarse dentro de contenedores Docker, tanto en local como en la nube.
- El hardware disponible (VRAM, CPU) puede variar entre ejecuciones, por lo que el sistema debe adaptarse dinámicamente a los recursos detectados.

2.5 Supuestos y dependencias

- Se asume disponibilidad de al menos una GPU local o en la nube compatible con CUDA o ROCm para obtener tiempos de procesamiento razonables; la ejecución en CPU se contempla como modo de contingencia, con tiempos de procesamiento significativamente mayores.
- Se asume que los vídeos de entrada contienen una pista de voz predominante y no música o efectos que impidan una separación de fuentes razonable.
- Se depende de la evolución y el mantenimiento continuo de los proyectos open source seleccionados en la fase de investigación tecnológica.
- Se asume acceso a Docker y, en su caso, a una cuenta activa en el proveedor de GPU alquilada elegido.

3. Requisitos Funcionales

A continuación se detallan los 13 requisitos funcionales identificados para el sistema, numerados de RF-01 a RF-13, siguiendo el orden natural del pipeline de procesamiento. Cada requisito incluye una descripción, sub-requisitos específicos, entradas, salidas, tecnologías candidatas a evaluar y criterios de aceptación.

RF-01 — Ingesta de vídeo

El sistema debe recibir uno o varios archivos de vídeo y extraer sus componentes fundamentales (audio, vídeo, subtítulos existentes y metadatos) para su procesamiento posterior en las siguientes etapas del pipeline.

Sub-requisitos:

- RF-01.1 — Debe admitir como mínimo los formatos MP4, MKV, MOV y AVI.
- RF-01.2 — Debe extraer la pista de audio en un formato sin pérdida (p. ej. WAV/PCM) para su procesamiento posterior.
- RF-01.3 — Debe extraer subtítulos embebidos si existen, conservando su codificación e idioma.
- RF-01.4 — Debe extraer y conservar los metadatos del archivo original (duración, resolución, framerate, códecs).
- RF-01.5 — Debe validar la integridad del archivo de entrada y reportar errores de forma clara si el archivo está corrupto o no es soportado.

Entradas	Archivos de vídeo en formatos MP4, MKV, MOV, AVI.
Salidas	Pista de audio en formato sin pérdida, pista de vídeo, subtítulos existentes extraídos, metadatos en formato estructurado (JSON).
Tecnologías a evaluar	FFmpeg (herramienta de referencia).
Criterios de aceptación	El sistema procesa correctamente los 4 formatos indicados sin pérdida de calidad ni de metadatos relevantes, y reporta errores comprensibles ante archivos no válidos.

RF-02 — Separación de voces (fuente de audio)

Antes de la transcripción, el sistema debe separar la voz de la música y los efectos de sonido, de forma que el motor de transcripción reciba una señal de voz limpia. El sistema debe seleccionar automáticamente el mejor método disponible según las características del audio de entrada.

Sub-requisitos:

- RF-02.1 — Debe generar como mínimo dos pistas de salida: voz aislada y resto (música/efectos).
- RF-02.2 — Debe evaluar automáticamente, mediante una métrica objetiva (p. ej. relación señal/ruido o puntuación de un modelo de calidad), cuál de los modelos disponibles ofrece el mejor resultado para el audio concreto.
- RF-02.3 — Debe ser configurable para forzar manualmente un modelo específico si el usuario lo desea.

Entradas	Pista de audio extraída del vídeo original (salida de RF-01).
Salidas	Pista de voz aislada; pista(s) de música/efectos separadas.
Tecnologías a evaluar	Demucs, UVR (Ultimate Vocal Remover), MDX.
Criterios de aceptación	La transcripción posterior (RF-03) mejora de forma medible al usar la voz separada frente al audio original, verificado mediante una comparación de tasa de error de palabra (WER).

RF-03 — Transcripción

Etapa considerada crítica del sistema. Debe generar texto transcrito con marcas de tiempo, puntuación, detección automática de idioma y segmentación, soportando vídeos de varias horas de duración sin degradación significativa de la calidad.

Sub-requisitos:

- RF-03.1 — Debe detectar automáticamente el idioma del audio de origen.
- RF-03.2 — Debe generar segmentos con marcas de tiempo de inicio y fin a nivel de frase.
- RF-03.3 — Debe soportar audio de larga duración (varias horas) mediante procesamiento por fragmentos si es necesario.
- RF-03.4 — Debe registrar métricas de confianza por segmento para facilitar la etapa de corrección (RF-04).

Entradas	Pista de voz aislada (salida de RF-02).
Salidas	Texto transcrito, timestamps por segmento, idioma detectado, segmentos de texto con nivel de confianza.
Tecnologías a evaluar	Whisper Large v3, Faster-Whisper, Distil-Whisper.
Criterios de aceptación	Se debe realizar una comparación documentada de precisión (WER), velocidad de procesamiento y consumo de VRAM entre las alternativas evaluadas antes de seleccionar la definitiva.

RF-04 — Corrección del texto transcrito

Dado que el motor de transcripción puede cometer errores, debe existir una etapa de post-procesado que corrija nombres propios y puntuación, una frases fragmentadas incorrectamente y elimine repeticiones, utilizando preferentemente un LLM ejecutado en local.

Sub-requisitos:

- RF-04.1 — Debe corregir errores ortográficos y de puntuación evidentes sin alterar el contenido semántico.
- RF-04.2 — Debe unificar nombres propios y terminología recurrente detectada en el vídeo.
- RF-04.3 — Debe eliminar repeticiones y muletillas de transcripción que no aporten valor al doblaje.
- RF-04.4 — Debe mantener trazabilidad entre el texto original transcrito y el texto corregido, para poder auditar los cambios introducidos.

Entradas	Texto transcrito bruto y segmentado (salida de RF-03).
Salidas	Texto corregido, coherente y listo para traducción, con registro de cambios respecto al original.
Criterios de aceptación	El texto corregido no debe alterar el significado original ni introducir contenido no presente en el audio (verificable mediante revisión muestral).

RF-05 — Traducción

El sistema debe traducir el texto corregido preservando la intención, el contexto, la terminología específica y las expresiones idiomáticas, evitando traducciones literales que resulten poco naturales en español.

Sub-requisitos:

- RF-05.1 — Debe conservar la segmentación y los timestamps de referencia del texto de origen.
- RF-05.2 — Debe permitir mantener un glosario de términos específicos del vídeo (nombres, jerga técnica).
- RF-05.3 — Debe adaptar expresiones idiomáticas a equivalentes naturales en español, evitando traducciones literales sin sentido.

Entradas	Texto corregido (salida de RF-04).
Salidas	Texto traducido al español, manteniendo segmentación y timestamps de referencia.
Tecnologías a evaluar	NLLB, MarianMT, Llama, Qwen, Mistral, Gemma.
Criterios de aceptación	Debe documentarse una comparación de calidad (evaluación humana o métrica automática, p. ej. COMET) entre los modelos evaluados antes de la selección final.

RF-06 — Adaptación del doblaje

No basta con traducir literalmente: el texto traducido debe adaptarse para que su duración al ser locutado sea aproximadamente equivalente a la del original, respetando pausas y respiraciones similares a las del audio fuente, de forma análoga a lo que realizan soluciones como Synthesia o HeyGen.

Sub-requisitos:

- RF-06.1 — Debe estimar la duración locutada del texto traducido antes de la síntesis de voz.
- RF-06.2 — Debe reescribir o comprimir/expandir el texto cuando la duración estimada se desvíe de un margen aceptable respecto al segmento original.
- RF-06.3 — Debe respetar las pausas naturales (comas, puntos, silencios) presentes en el audio original.

Entradas	Texto traducido (salida de RF-05) y timestamps originales.
Salidas	Texto adaptado con duración estimada compatible con el vídeo original.
Criterios de aceptación	La duración estimada del texto adaptado no debe desviarse más de un margen razonable respecto al segmento original (umbral a definir en la fase de investigación técnica, orientativamente ±10%).

RF-07 — Clonación de voz (Voice Cloning)

Componente central del sistema. Debe extraer las características de la voz original (timbre, emoción, velocidad, tono) y generar una voz en español que las conserve de la forma más fiel posible.

Sub-requisitos:

- RF-07.1 — Debe generar un perfil de voz reutilizable a partir de una muestra breve de la voz original.
- RF-07.2 — Debe conservar el timbre y el tono característicos del hablante original.
- RF-07.3 — Debe adaptar la emoción y la prosodia percibidas en el audio original al nuevo audio generado.
- RF-07.4 — Debe soportar múltiples hablantes en un mismo vídeo si el vídeo original los contiene.

Entradas	Pista de voz aislada (RF-02) y texto adaptado (RF-06).
Salidas	Modelo o perfil de voz clonada reutilizable para la etapa de síntesis (RF-08).
Tecnologías a evaluar	XTTS, OpenVoice, Fish Speech, CosyVoice, Dia, Spark-TTS, E2 TTS, entre otras a investigar.
Criterios de aceptación	Debe realizarse una comparación exhaustiva de las tecnologías candidatas en cuanto a similitud de voz (p. ej. mediante métricas de similitud de speaker embedding), naturalidad percibida y requisitos de cómputo.

RF-08 — Generación del nuevo audio (TTS)

El sistema debe sintetizar el audio en español a partir de la voz clonada y el texto adaptado, con calidad de 44.1 kHz o 48 kHz y sin artefactos audibles perceptibles.

Sub-requisitos:

- RF-08.1 — Debe generar audio a una frecuencia de muestreo de 44.1 kHz o 48 kHz.
- RF-08.2 — Debe evitar artefactos audibles (clics, distorsión, robotización no deseada).
- RF-08.3 — Debe generar el audio segmento a segmento, respetando el orden y los timestamps de referencia.

Entradas	Perfil de voz clonada (RF-07) y texto adaptado (RF-06).
Salidas	Pista de audio en español, sin artefactos, a 44.1/48 kHz, segmentada según el guion adaptado.
Criterios de aceptación	Verificación auditiva y/o mediante métrica automatizada de ausencia de artefactos y de la frecuencia de muestreo requerida.

RF-09 — Sincronización temporal

Dado que el nuevo audio generado probablemente tenga una duración distinta a la del original, el sistema debe ajustar temporalmente el audio para encajar con el vídeo, sin degradar de forma perceptible la calidad ni el tono de la voz.

Sub-requisitos:

- RF-09.1 — Debe ajustar la duración del audio generado mediante técnicas de estiramiento temporal sin alterar el tono (pitch) de la voz.
- RF-09.2 — Debe emplear alineación forzada para verificar la correspondencia entre el audio generado y los timestamps del vídeo original.
- RF-09.3 — Debe reportar el desfase residual tras el ajuste para su verificación.

Entradas	Audio en español generado (RF-08) y timestamps originales.
Salidas	Audio ajustado temporalmente, sincronizado con el vídeo original, junto con un informe de desfase residual.
Tecnologías a evaluar	Time Stretch, Forced Alignment, Dynamic Time Warping, Montreal Forced Aligner.
Criterios de aceptación	El desfase resultante entre audio y vídeo debe mantenerse por debajo de un umbral aceptable definido en la fase de diseño (orientativamente inferior a 100 ms por segmento).

RF-10 — Sincronización labial (Lip Sync) — Opcional

El sistema debe permitir, de forma activable/desactivable, sincronizar el movimiento labial del vídeo con el nuevo audio generado, siempre que la relación calidad/coste computacional lo justifique.

Sub-requisitos:

- RF-10.1 — Debe poder activarse o desactivarse mediante un parámetro de configuración, sin afectar al resto de etapas del pipeline.
- RF-10.2 — Cuando esté activado, debe generar un vídeo con movimiento labial coherente con el nuevo audio.
- RF-10.3 — Debe documentarse el coste computacional adicional de esta etapa frente a su beneficio percibido.

Entradas	Vídeo original y audio sincronizado (RF-09).
Salidas	Vídeo con sincronización labial ajustada a la nueva pista de audio (si la función está activada).
Tecnologías a evaluar	Wav2Lip, MuseTalk, LatentSync, InfiniteTalk, entre otras a investigar.
Criterios de aceptación	La función debe poder activarse o desactivarse mediante configuración, sin afectar al resto del pipeline cuando está desactivada.

RF-11 — Mezcla final (Mux)

El sistema debe combinar el vídeo original (o con lip sync aplicado), el nuevo audio y los subtítulos generados en un único archivo de salida, conservando la máxima calidad posible.

Sub-requisitos:

- RF-11.1 — Debe combinar vídeo, audio y subtítulos en contenedores estándar (p. ej. MP4/MKV).
- RF-11.2 — Debe conservar la resolución y el framerate original del vídeo salvo indicación contraria.
- RF-11.3 — Debe permitir generar una versión con subtítulos embebidos (hardsub) y otra con subtítulos como pista independiente (softsub).

Entradas	Vídeo original o con lip sync (RF-10), audio final sincronizado (RF-09), subtítulos (RF-12).
Salidas	Archivo de vídeo final con audio doblado y subtítulos integrados o adjuntos.
Tecnologías a evaluar	FFmpeg.
Criterios de aceptación	El archivo resultante debe reproducirse correctamente en reproductores estándar sin errores de sincronía entre audio, vídeo y subtítulos.

RF-12 — Generación de subtítulos

El sistema debe generar automáticamente subtítulos en español, en inglés y en formato bilingüe, a partir del texto traducido/adaptado y de los timestamps calculados durante el pipeline.

Sub-requisitos:

- RF-12.1 — Debe generar subtítulos en español a partir del texto adaptado (RF-06).
- RF-12.2 — Debe generar subtítulos en inglés a partir del texto transcrito/corregido original si el idioma de origen no es el inglés, o traducido si aplica.
- RF-12.3 — Debe generar una versión bilingüe (español + inglés) combinando ambas pistas de texto.
- RF-12.4 — Debe exportar en formatos SRT, VTT y ASS, validando su correcta sintaxis.

Entradas	Texto traducido/adaptado (RF-05/RF-06) y timestamps.
Salidas	Archivos de subtítulos en formatos SRT, VTT y ASS, en español, inglés y bilingüe.
Criterios de aceptación	Los subtítulos deben estar correctamente sincronizados con el audio final y ser válidos según el estándar de cada formato (verificable con un validador de sintaxis).

RF-13 — Procesamiento masivo por lotes

El sistema debe permitir procesar carpetas completas con múltiples vídeos, gestionando una cola automática de procesamiento hasta obtener todos los resultados, sin intervención manual entre vídeos.

Sub-requisitos:

- RF-13.1 — Debe detectar automáticamente todos los vídeos soportados dentro de una carpeta indicada.
- RF-13.2 — Debe gestionar una cola de procesamiento secuencial o paralela según los recursos de GPU disponibles.
- RF-13.3 — Debe continuar con el siguiente vídeo de la cola si uno de ellos falla, registrando el error sin detener el proceso global.
- RF-13.4 — Debe generar un informe final del procesamiento por lotes (vídeos completados, fallidos y tiempo total empleado).

Entradas	Carpeta con múltiples archivos de vídeo (p. ej. 100 vídeos).
Salidas	Resultados procesados para cada vídeo de la carpeta e informe consolidado del lote.
Criterios de aceptación	El sistema debe completar el procesamiento de todos los vídeos de la cola sin requerir supervisión continua, y debe recuperarse de fallos individuales sin detener el lote completo.

4. Requisitos No Funcionales

Además de las funciones descritas en la Sección 3, el sistema debe satisfacer un conjunto de requisitos no funcionales relacionados con el rendimiento, la escalabilidad, la portabilidad, el coste y la calidad global del resultado.

Código	Requisito	Descripción
RNF-01	Rendimiento y uso eficiente de GPU	El sistema debe detectar automáticamente la VRAM disponible y el tipo de aceleración (CUDA, ROCm) y seleccionar automáticamente entre modelo grande, modelo pequeño o ejecución en CPU según los recursos disponibles, maximizando el rendimiento sin intervención manual.
RNF-02	Portabilidad y ejecución en GPU alquilada	El sistema debe poder ejecutarse sin modificaciones de código en proveedores de GPU en la nube como RunPod, Vast.ai, Lambda Labs, Paperspace o CoreWeave, empaquetado íntegramente en contenedores Docker.
RNF-03	Modularidad y arquitectura desacoplada	Cada módulo del pipeline (extracción, separación, transcripción, corrección, traducción, clonación de voz, TTS, alineación, lip sync, mezcla) debe ser independiente y sustituible sin afectar al resto del sistema.
RNF-04	Automatización y usabilidad	El proceso completo debe ejecutarse mediante un único punto de disparo ("un solo botón"), sin necesidad de ejecutar scripts ni comandos manuales por parte del usuario durante el uso habitual.
RNF-05	Costes	El sistema debe basarse en software 100% local y de código abierto, sin APIs de pago, sin suscripciones ni coste por minuto. Único coste admitido: el alquiler puntual de GPU en la nube cuando sea necesario.
RNF-06	Calidad global del resultado	El sistema debe maximizar calidad de traducción, naturalidad de la voz, similitud con la voz original, precisión de sincronización, velocidad y estabilidad, priorizando siempre el mejor rendimiento/calidad disponible en el momento de la implementación frente a la popularidad de la herramienta.
RNF-07	Escalabilidad	El sistema debe soportar el incremento de carga (mayor número de vídeos o mayor duración de los mismos) sin rediseño estructural, permitiendo escalar horizontalmente mediante múltiples instancias de GPU alquilada si el volumen de trabajo lo requiere.
RNF-08	Disponibilidad y tolerancia a fallos	El sistema debe recuperarse ante fallos puntuales de un módulo o de un vídeo concreto dentro de un lote, sin necesidad de reiniciar todo el proceso, conservando el progreso ya alcanzado.
RNF-09	Mantenibilidad	El sistema debe estar organizado en módulos claramente documentados, de forma que una nueva tecnología (p. ej. un nuevo motor de transcripción) pueda integrarse sustituyendo un único módulo, sin necesidad de modificar el resto del pipeline.
RNF-10	Seguridad y privacidad de los datos	Dado que el procesamiento puede ejecutarse en proveedores de GPU alquilada, el sistema debe evitar la persistencia innecesaria de los vídeos y audios procesados en dichos proveedores más allá del tiempo estrictamente necesario para el procesamiento.
RNF-11	Observabilidad	El sistema debe registrar logs estructurados por etapa y por vídeo procesado, permitiendo identificar en qué punto del pipeline se ha producido un error o una degradación de calidad.

5. Arquitectura del Sistema

5.1 Arquitectura del pipeline

El sistema se estructura como un pipeline lineal de módulos desacoplados, donde cada etapa consume la salida de la anterior. Esto permite sustituir cualquier componente (p. ej. cambiar el motor de transcripción) sin necesidad de modificar el resto del sistema. La siguiente tabla resume el flujo completo de procesamiento:

Etapa	Descripción
1	Vídeo de entrada
2	Extracción de audio, vídeo y metadatos (RF-01)
3	Separación de voz / música / efectos (RF-02)
4	Transcripción (RF-03)
5	Corrección del texto (RF-04)
6	Traducción (RF-05)
7	Adaptación del doblaje (RF-06)
8	Clonación de voz (RF-07)
9	Síntesis de audio / TTS (RF-08)
10	Alineación y sincronización temporal (RF-09)
11	Sincronización labial — opcional (RF-10)
12	Mezcla final / Mux (RF-11)
13	Generación de subtítulos (RF-12)
14	Salida final (vídeo doblado + subtítulos)

El procesamiento masivo (RF-13) opera sobre este mismo pipeline, encolando múltiples vídeos de entrada y ejecutando cada instancia de forma secuencial o paralela según los recursos de GPU disponibles.

5.2 Arquitectura de despliegue

El sistema debe empaquetarse mediante contenedores Docker, de forma que la misma imagen pueda ejecutarse tanto en un equipo local con GPU propia como en un proveedor de GPU alquilada, sin cambios en el código fuente. Se contemplan los siguientes escenarios de despliegue:

Escenario	Descripción
Local con GPU	Ejecución completa en un equipo local con GPU NVIDIA o AMD compatible, sin coste recurrente, ideal para volúmenes moderados de vídeo.
Local sin GPU (CPU)	Modo de contingencia con modelos reducidos, adecuado para pruebas o vídeos cortos, con tiempos de procesamiento notablemente mayores.
GPU alquilada (nube)	Despliegue de la misma imagen Docker en RunPod, Vast.ai, Lambda Labs, Paperspace o CoreWeave para procesar grandes volúmenes o vídeos largos, pagando únicamente por el tiempo de GPU utilizado.

5.3 Flujo de datos y formatos intermedios

Cada etapa del pipeline debe leer y escribir sus resultados en formatos intermedios estandarizados (por ejemplo, JSON para texto y metadatos, WAV para audio intermedio, y los formatos de vídeo/subtítulo correspondientes en las etapas finales), de forma que cualquier módulo pueda ser inspeccionado, depurado o sustituido sin romper la compatibilidad con el resto del pipeline.

5.4 Gestión de errores y reintentos

- Cada etapa debe capturar y registrar sus propios errores sin detener el procesamiento de otros vídeos en cola (ver RNF-08).
- El sistema debe permitir reintentar automáticamente una etapa fallida un número configurable de veces antes de marcar el vídeo como fallido.
- El sistema debe conservar los resultados intermedios ya generados para un vídeo, de forma que un reintento no obligue a repetir etapas ya completadas correctamente.

6. Fase Previa de Investigación Tecnológica

Antes de iniciar la implementación de cualquier etapa del pipeline, se debe realizar una investigación comparativa exhaustiva de las mejores tecnologías open source disponibles para cada fase: transcripción, separación de voz, traducción, clonación de voz, síntesis de voz, alineación temporal, sincronización labial y renderizado.

6.1 Metodología de evaluación

Criterios de evaluación obligatorios para cada tecnología candidata:

- Calidad de resultado (precisión, naturalidad, similitud de voz, según corresponda a la etapa).
- Rendimiento (velocidad de procesamiento por minuto de audio/vídeo).
- Requisitos de GPU / VRAM y compatibilidad con CPU.
- Tipo de licencia (compatibilidad con uso local, comercial o no comercial, y sin coste).
- Actividad y mantenimiento de la comunidad del proyecto (frecuencia de actualizaciones, issues abiertos).
- Facilidad de integración con el resto del pipeline (formatos de entrada/salida, disponibilidad de API o librería).

6.2 Matriz de comparación (plantilla)

Para cada etapa del pipeline se debe completar una matriz de comparación equivalente a la siguiente plantilla antes de tomar una decisión definitiva:

Tecnología	Calidad	Velocidad	VRAM	Licencia	Comunidad	Integración
Candidata 1	—	—	—	—	—	—
Candidata 2	—	—	—	—	—	—
Candidata 3	—	—	—	—	—	—

6.3 Tecnologías candidatas por etapa (resumen)

Etapa	Tecnologías candidatas a evaluar
Separación de voz	Demucs, UVR, MDX
Transcripción	Whisper Large v3, Faster-Whisper, Distil-Whisper
Traducción	NLLB, MarianMT, Llama, Qwen, Mistral, Gemma
Clonación de voz / TTS	XTTS, OpenVoice, Fish Speech, CosyVoice, Dia, Spark-TTS, E2 TTS
Alineación temporal	Time Stretch, Forced Alignment, Dynamic Time Warping, Montreal Forced Aligner
Sincronización labial	Wav2Lip, MuseTalk, LatentSync, InfiniteTalk
Extracción / mezcla	FFmpeg

Esta lista tiene carácter orientativo y no debe interpretarse como un requisito cerrado: si en el momento de la implementación existen alternativas más recientes o superiores, deben evaluarse e incorporarse siempre que se documente y justifique la comparación correspondiente.

7. Gestión de Riesgos

Se identifican a continuación los principales riesgos del proyecto, su probabilidad e impacto estimados, y las medidas de mitigación propuestas.

ID	Riesgo	Prob.	Impacto	Mitigación
R-01	Obsolescencia rápida de los modelos de IA seleccionados	Alta	Medio	Mantener la arquitectura desacoplada (RNF-03) y repetir la fase de investigación tecnológica periódicamente antes de cada nueva versión.
R-02	Calidad insuficiente de la clonación de voz en idiomas o acentos poco representados	Media	Alto	Evaluar múltiples motores de voice cloning (RF-07) y permitir fallback a un modelo alternativo por vídeo.
R-03	Coste elevado de GPU alquilada en vídeos largos o lotes grandes	Media	Medio	Optimizar el uso de GPU (RNF-01), permitir procesamiento por fragmentos y estimar coste antes de lanzar un lote de gran tamaño.
R-04	Desincronización entre audio doblado y vídeo original	Media	Alto	Reforzar la etapa de alineación temporal (RF-09) con verificación automática del desfase residual.
R-05	Errores de transcripción en audios con ruido de fondo o múltiples hablantes	Media	Medio	Aplicar separación de fuentes robusta (RF-02) y permitir revisión/corrección asistida (RF-04).
R-06	Dependencia de proyectos open source con mantenimiento discontinuado	Baja	Alto	Incluir la actividad de mantenimiento como criterio de selección obligatorio (Sección 6.1) y mantener alternativas de respaldo documentadas.
R-07	Fallos parciales durante el procesamiento masivo por lotes	Media	Medio	Diseñar el sistema para continuar el lote ante fallos individuales (RNF-08) y generar informes de error por vídeo (RF-13.3).

8. Plan de Implementación por Fases

Se propone una implementación incremental del sistema, organizada en fases que permiten validar cada bloque funcional antes de avanzar al siguiente, reduciendo el riesgo de integración final.

Fase	Nombre	Descripción
Fase 0	Investigación tecnológica inicial	Evaluación comparativa de tecnologías candidatas para cada etapa del pipeline, según la metodología de la Sección 6.
Fase 1	Ingesta y preprocesado	Implementación de RF-01 (ingesta) y RF-02 (separación de voces), con validación sobre una muestra de vídeos de prueba.
Fase 2	Transcripción y corrección	Implementación de RF-03 y RF-04, con medición de tasa de error de palabra (WER) antes y después de la corrección.
Fase 3	Traducción y adaptación	Implementación de RF-05 y RF-06, incluyendo el mecanismo de ajuste de duración del texto traducido.
Fase 4	Clonación de voz y síntesis	Implementación de RF-07 y RF-08, con evaluación de similitud de voz y calidad de audio generado.
Fase 5	Sincronización y mezcla	Implementación de RF-09, RF-10 (opcional), RF-11 y RF-12, integrando el vídeo final con audio y subtítulos.
Fase 6	Procesamiento masivo y despliegue	Implementación de RF-13 y de los requisitos no funcionales de despliegue (RNF-01, RNF-02, RNF-07, RNF-08), incluyendo el empaquetado en Docker y las pruebas en GPU alquilada.
Fase 7	Pruebas integrales y ajuste de calidad	Ejecución de la estrategia de pruebas descrita en la Sección 9 sobre el pipeline completo y ajuste fino de los parámetros de calidad.

9. Criterios de Aceptación y Estrategia de Pruebas

9.1 Pruebas funcionales

- Verificación individual de cada requisito funcional (RF-01 a RF-13) mediante casos de prueba específicos con vídeos de referencia.
- Prueba de extremo a extremo: un vídeo de entrada en un idioma de origen produce un vídeo de salida doblado al español, sincronizado y con subtítulos, sin intervención manual.
- Prueba de procesamiento por lotes con al menos 10 vídeos de prueba, incluyendo al menos uno diseñado para fallar deliberadamente, verificando que el resto del lote se complete correctamente.

9.2 Pruebas de rendimiento

- Medición del tiempo total de procesamiento por minuto de vídeo de entrada, en local y en GPU alquilada.
- Medición del consumo de VRAM por etapa, verificando la selección automática de modelo grande/pequeño/CPU (RNF-01).
- Prueba de escalabilidad incrementando el tamaño del lote de vídeos procesados.

9.3 Pruebas de calidad de doblaje

- Evaluación de la tasa de error de palabra (WER) de la transcripción antes y después de la corrección (RF-04).
- Evaluación de la calidad de traducción mediante revisión humana o métricas automáticas de referencia.
- Evaluación de la similitud de voz entre el audio original y el audio doblado mediante métricas de speaker embedding o evaluación auditiva estructurada.
- Evaluación del desfase temporal entre audio y vídeo tras la sincronización (RF-09), verificando que se mantenga por debajo del umbral definido.
- Evaluación cualitativa de la sincronización labial (RF-10), cuando esté activada, mediante revisión visual.

9.4 Criterios generales de aceptación del sistema

- El sistema procesa de extremo a extremo un vídeo de entrada en cualquiera de los formatos soportados y produce un vídeo doblado al español con subtítulos, sin intervención manual entre etapas.
- El sistema funciona correctamente tanto en entorno 100% local como desplegado en un proveedor de GPU alquilada, sin cambios en el código fuente.
- El sistema procesa lotes de múltiples vídeos de forma desatendida, recuperándose de fallos individuales.
- Cada módulo puede sustituirse de forma independiente sin romper el resto del pipeline.
- No se incurre en costes recurrentes de licencias, suscripciones o APIs de pago; el único coste variable admitido es el de alquiler de GPU en la nube.

10. Anexos

Anexo A — Estructura de carpetas propuesta

Se propone una estructura de carpetas de trabajo que refleje la naturaleza desacoplada del pipeline, facilitando la inspección y depuración de resultados intermedios en cada etapa:

```
proyecto_doblaje/
■■■ input/                  # Vídeos de entrada a procesar
■■■ work/
■   ■■■ /
■   ■   ■■■ 01_ingesta/     # Audio, vídeo y metadatos extraídos (RF-01)
■   ■   ■■■ 02_separacion/  # Voz aislada y música/efectos (RF-02)
■   ■   ■■■ 03_transcripcion/  # Texto, timestamps, idioma (RF-03)
■   ■   ■■■ 04_correccion/  # Texto corregido (RF-04)
■   ■   ■■■ 05_traduccion/  # Texto traducido (RF-05)
■   ■   ■■■ 06_adaptacion/  # Texto adaptado (RF-06)
■   ■   ■■■ 07_voz_clonada/ # Perfil de voz (RF-07)
■   ■   ■■■ 08_tts/         # Audio sintetizado (RF-08)
■   ■   ■■■ 09_sincronia/   # Audio ajustado temporalmente (RF-09)
■   ■   ■■■ 10_lipsync/     # Vídeo con lip sync, si aplica (RF-10)
■   ■   ■■■ 11_mezcla/      # Vídeo final mezclado (RF-11)
■   ■   ■■■ 12_subtitulos/  # SRT / VTT / ASS (RF-12)
■■■ output/                 # Vídeos finales entregables
■■■ logs/                   # Registro de ejecución y errores por vídeo
```

Anexo B — Ejemplo de configuración del pipeline

El sistema debe soportar un archivo de configuración declarativo que permita ajustar parámetros sin modificar código, como el siguiente ejemplo orientativo en formato YAML:

```
pipeline:
  idioma_destino: es
  lip_sync: false
  formatos_subtitulos: [srt, vtt, ass]
  hardware:
    modo: auto        # auto | gpu | cpu
    vram_minima_gb: 8
  procesamiento_lote:
    max_paralelo: 2
    reintentos_por_etapa: 2
  gpu_alquilada:
    proveedor: runpod   # runpod | vast.ai | lambda_labs | paperspace | coreweave
    activar_solo_si_local_insuficiente: true
```

Anexo C — Glosario extendido

Término	Definición
Speaker embedding	Representación vectorial de las características de una voz, utilizada para medir similitud entre la voz original y la voz clonada.
WER (Word Error Rate)	Tasa de error de palabra: métrica estándar para evaluar la precisión de una transcripción frente a una referencia.
Hardsub / Softsub	Hardsub: subtítulos incrustados permanentemente en la imagen del vídeo. Softsub: subtítulos como pista independiente, activable/desactivable.
Prosodia	Conjunto de elementos del habla como el ritmo, la entonación y el énfasis, relevantes para que la voz clonada suene natural.

Término	Definición
Speaker diarization	Proceso de identificar y separar los distintos hablantes presentes en un mismo audio.